

「BDA 11기 학회원 최종 과제」 분석 보고서

*제출시 파일 이름은 '이름_2자리 숫자_최종과제_제출'입니다.

과 제 명	조별활동 조편성 아이디어 및 전략 제시	성 명	이호준
활용데이터	test.csv , train.csv		

1. 주제 선정 및 분석 배경

- 주제 선정 및 분석 배경 :

조별활동은 협업 학습과 네트워크 형성을 위한 핵심 프로그램이다. 그러나 일부인원의 중도 이탈은 조 전체의 활동 지속성과 성과에 직접적인 영향을 미친다. 특히조 단위 활동은 인원 규모가 제한되어 있어, 한 명의 이탈만으로도 활동 부담증가와 참여 동기 저하로 이어질 가능성이 존재한다.

이에 본 프로젝트 분석에서 조별활동에서 발생하는 이탈자의 현황을 정량적으로 확인하고, 이탈률차이가 나타나는 주요 요인을 비교·분석하여 운영 차원의 개선 전략을 도출하는것을 목적으로 하였다.

- 문제정의 :

따라서 다음과 같은 문제 정의를 통해 해결하고자 하였다.

1. 활동 중 전체 이탈률은 어느 수준인가?
2. 신분(직장)에 따른 이탈률이 차이가 있을까?
3. 어떤 방식의 활동임에 따라 이탈률이 달라질까?

이러한 문제 정의를 통해 단순 현황 파악과 더불어, 이탈의 정도가 어느 정도인지, 신분과 활동 방식에 따라 어떻게 달라지는 파악하고, 이탈 위험을 완화할 수 있는 운영 전략을 수립하고자 한다.

또한 이러한 전략을 시사함으로써 이후 다음 기수부터 적용하여, 그들의 이탈률을 감소시키고, 학회원들이 중도 포기 없이 성장을 완주할 수 있는 '이탈 방지 안전망'을 구축하고, 나아가 학회의 학술적 깊이와 네트워크 가치를 동반 상승시키고자 한다.

2. 분석 결과 상세 내용

- 분석 데이터


분석을 위한 데이터로 제공된 2개의 데이터를 사용했다.

-> train.csv

-> test.csv

- 전체 이수률(이탈률)


1. Total Completion vs Dropout



전체 학습자 중 약 70.2%가 이탈(Dropout)하고, 29.8%만이 수료(Completed)하는 것으로 나타난다. 전체적으로 이탈률이 매우 높은 편이므로, 초기 이탈 방지 대책이 시급함을 정량적으로 보여준다.


- 신분(그룹)별 이수률(이탈률)

2. Dropout Rate by Job Status




대학원생(Grad Student)그룹의 이탈률이 가장 높게 나타났다. 반면, 학생(Student)과 직장인(Professional)그룹은 상대적으로 수료율이 조금 더 높지만, 여전히 이탈 비중이 크게 나타난다.

- 팀/개인 별 이수률(이탈률)



팀(Team)활동과 개인(Individual)활동 간의 이탈률 차이는 아주 크지는 않지만, 팀 프로젝트 형태에서 이탈자가 다소 이탈이 많이 발생한다는 것을 알 수 있다.


- 참여 형태에 따른 이수률(이탈률)



'오프라인 참여를 희망(네. 오프라인으로 참여하고 싶어요)'했던 사람들의 절대적인 수가 가장 많지만, 그만큼 이탈자 수도 가장 많았다.

희망하는 활동 방식이 제공되지 않았거나 오프라인 활동의 제약이 이탈에 영향을 주었는지 추가 검토가 필요하다.

- 각각의 피쳐 상관관계



데이터의 수치형 변수들 간의 관계를 시각화한 결과로, 색이 붉을수록 양의 상관관계(함께 증가), 푸를수록 음의 상관관계(하나가 증가할 때 감소)가 강함을 의미한다.

강한 상관관계: class1, class2, class3간에는 0.8 이상의 매우 높은 상관관계가 관찰된다. 이는 유사한 성격의 수업이거나 학습 패턴이 비슷하다는 점을 시사한다.

학기 수와 성취: completed_semester(이수 학기)와 class3사이에는 약 0.33의 약한 양의 상관관계가 있어, 학년이 높을수록 특정 클래스의 성과가 약간 높은 경향이 보인다.

수료 여부(completed): 현재 수치형 데이터만으로는 최종 수료 여부와 강한 선형 관계를 가진 피쳐가 뚜렷하지 않다. 이는 수료 여부가 수치보다는 전공, 직업, 참여 동기같은 범주형(텍스트) 데이터의 영향을 더 많이 받을 가능성이 큼을 의미한다.

- 종합 인사이트

1. 수료율 29.8% 대비 이탈률 70.2%로, 학습자 10명 중 7명이 중도 포기한다.

=> 교육 과정의 난이도가 지나치게 높거나, 초기 동기부여가 지속되지 못함을 시사한다.

=> 예측 모델에서 다른 '활동 초기의 데이터(class 참여도 등)'가 실제 수료와 직결될 가능성이 높다.

2. 대학생이나 직장인보다 대학원생(Grad Student)그룹에서 이탈 비중이 가장 두드러진다.

=> 대학원생은 데이터 분석에 대한 니즈는 높으나, 본인의 연구 및 학업 스케줄과의 충돌이 잦아 우선순위에서 밀릴 확률이 크다.

3. 팀 프로젝트와 개인 프로젝트 간의 이탈률은 유사하다.

=> 팀 프로젝트와 개인 프로젝트의 유무는 크게 의미가 있다고 보기 어렵다.

4. 오프라인 참여를 강력히 희망했던 학습자들 사이에서 이탈자가 다수 발생했다.

=> 오프라인 활동에 대한 기대(네트워킹, 대면 학습)가 실제 운영 환경(이동 거리, 시간 소요, 대면 기회의 부족 등)과 맞지 않을 때 실망감이 이탈로 이어질 수 있다.

- 데이터 전처리 과정 (Data Preprocessing)

데이터 검사 및 정제:

- 결측치 비율 분석 및 데이터 타입(Numerical vs Categorical) 확인.
- ID등 예측에 불필요한 식별자 컬럼 제거.

파생 변수 생성 (Feature Engineering):

- total_class_count: 수강 신청한 클래스 수의 합계를 통해 학습 의지 수량화.
- text_len: 지원 동기 및 얻고자 하는 바의 텍스트 길이를 추출하여 참여 열의도 파악.
- job_group: 유사한 성격의 신분(예: 학생군, 직장인군)을 그룹화하여 노이즈 감소.

전처리 파이프라인 (Pipeline) 구축:

- 수치형 데이터: SimpleImputer(strategy='median')로 결측치를 채우고, StandardScaler를 통해 데이터 스케일 정규화.

- 범주형 데이터: SimpleImputer(strategy='constant', fill_value='Missing')로 결측치를 새로운 범주로 처리하고, OneHotEncoder또는 CatBoost 자체 인코딩 활용.

- 자동화: ColumnTransformer를 사용하여 데이터 누수(Data Leakage)를 방지하고 일관된 변환 적용.

- 분석 툴 및 환경

- 언어 및 환경: Python (Google Colab / Jupyter Notebook)

- 데이터 핸들링: Pandas, Numpy

- 시각화: Matplotlib, Seaborn(이탈률 현황 및 신분별/타입별 비교 분석)

- 머신러닝 라이브러리: Scikit-learn, CatBoost

- 알고리즘 및 모델링 방법론

- CatBoostClassifier

선정 이유: 학습 데이터 내에 범주형 변수(전공, 신분 등)가 많고 결측치가 빈번한 특성을 고려할 때, 범주형 데이터를 효율적으로 처리하고 과적합(Overfitting)에 강한 CatBoost를 최종 모델로 선정.

- 모델 검증 및 최적화 방법론

교차 검증 (Stratified K-Fold): 데이터를 5개 그룹으로 나누어 검증하여 모델의 일반화 성능 확보 및 점수 변동성 최소화.

임계값 최적화 (Threshold Optimization): 단순히 확률 0.5를 기준으로 분류하지 않고, 검증 데이터에서 **F1-score가 최대화되는 최적의 임계값을 찾아 적용.

- 결과물에 대한 해석 및 인사이트

1. "대학원생" 그룹의 이탈, '의지'가 아닌 '환경'의 문제

=> 데이터상 대학원생의 이탈률이 가장 높았다. 이는 분석 역량이나 의지가 부족해서가 아니라, 연구실 일정 등 예측 불가능한 스케줄때문으로 나타난다.

=> 이들에게는 '실시간 참여'보다는 '녹화본 학습'이나 '비동기식 과제 제출' 비중을 높여주는 유연한 커리큘럼을 제공할 때 리텐션(Retention)이 올라갈 것이라 생각한다.

2. "오프라인 선호자"의 역설

=> 오프라인을 강력히 희망했던 인원들의 이탈이 많았으며, 기대했던 '대면 네트워킹'이 충분하지 않거나, 오프라인 장소까지의 '이동 거리'라는 물리적 장벽을 간과했기 때문이다.

=> 다음 기수 모집 시, 거주지 데이터를 기반으로 **지역별 거점 소모임**을 매칭해주거나, 오프라인 갈등을 해소할 수 있는 강력한 '오프라인 밋업(Meet-up)'을 초기에 배치하여 소속감을 고취한다.

- 최종 결론 (Executive Summary)

본 분석 결과는 학습자 수료의 핵심이 '시간적 여유'와 '사회적 결속력'에 있음을 보여준다.

1. 예측 모델은 수료 가능성이 낮은 인원을 조기에 식별하여 운영진의 관리 효율을 높여준다.
2. 데이터 인사이트는 신분별/선호별 맞춤형 운영 가이드를 제공하여 학회의 질적 성장을 견인한다.

마지막 결론

※ 데이터 기반 접근은 단순히 이탈을 막는 것을 넘어, 학회원 개개인에게 최적화된 학습 경험을 제공함으로써 학회의 브랜드 가치를 높이는 결과를 가져올 것이다.

4. 참고 문헌 출처 등

- 참고한 관련 문헌이 있을 경우 작성

※ 5~10장 내외로 작성